

Prueba Técnica — Ingeniero(a) Data Mesh

Cliente 360: Riesgo de Abandono y Oportunidad de Upsell

Entregado por: Ricardo Suárez

Dominio: Postpago Residencial

Plataforma: Databricks Lakehouse + Unity Catalog

Fecha: 13 de septiembre de 2026

T1. Data Mesh aplicado al caso

Data Mesh es un modelo en el que los dominios de negocio asumen responsabilidad sobre sus datos y los publican como productos reutilizables, en lugar de depender de un equipo central para cada necesidad.

En este caso, Postpago Residencial es el dominio productor de *cliente_360_churn_upsell*. El producto consolida clientes activos, productos, uso y PQR para que Mercadeo Digital identifique riesgo de abandono y oportunidades de upsell.

Principio	Aplicación en el caso
Dominio como dueño del dato	Postpago Residencial define las reglas de churn y upsell, responde por la calidad y valida las decisiones de negocio.
Datos como producto	La tabla Gold tiene propósito, consumidores, esquema, SLA, reglas de calidad y política de acceso definidos en un data contract.
Plataforma self-service	El dominio carga sus CSV, ejecuta el pipeline Bronze–Silver–Gold en Databricks y obtiene Gold mediante un Job con tareas y dependencias.
Gobierno federado	Unity Catalog organiza las capas, administra permisos y permite trazabilidad. El dominio trabaja con autonomía, bajo controles comunes.

El Job quedó manual para la prueba, evitando ejecuciones y consumo de cómputo sin nuevos archivos que procesar. En producción puede programarse con la frecuencia requerida por el SLA —por ejemplo, diaria— sin cambiar la lógica de los notebooks; solo se agrega un schedule o trigger al Job.

T2. Unity Catalog y capas L1–L3

Unity Catalog es la capa de gobierno de Databricks. Centraliza el catálogo de datos, permisos, linaje y auditoría, evitando que las tablas se administren sin convenciones de dominio o seguridad.

Para este caso se define el catálogo `claro_postpago`:

Capa	Esquema	Función
L1 Raw / Bronze	<code>claro_postpago.l1_raw</code>	Conserva los CSV como tablas Delta sin limpieza funcional; agrega metadatos de origen, fecha de carga, ejecución y hash.
L2 Curated / Silver	<code>claro_postpago.l2_curated</code>	Normaliza, tipa y valida datos; contiene la tabla de cuarentena de uso.
L3 Certified / Gold	<code>claro_postpago.l3_certified</code>	Publica el producto certificado <code>cliente_360_churn_upsell</code> .

Ejemplos de objetos:

- `claro_postpago.l1_raw.dim_cliente_bronze`
- `claro_postpago.l2_curated.fact_uso_servicio_silver`
- `claro_postpago.l3_certified.cliente_360_churn_upsell`

Esta separación conserva evidencia del origen, evita que datos inválidos lleguen a consumo y permite que Mercadeo Digital acceda solo a información certificada. Gold no expone documento ni `nombre_completo`.

T3. Data contract

Un data contract define el acuerdo entre el dominio productor y los consumidores sobre el producto, su esquema, reglas de negocio, calidad, frecuencia y acceso.

En `cliente_360_churn_upsell`, el contrato se documenta en `data_contract_cliente_360.md` y se aplica técnicamente en el notebook `20_gold_cliente_360.py`, justo antes de publicar la tabla Gold.

El notebook construye el resultado con el grano definido —un registro por cliente activo—, calcula `churn_risk` y `upsell_flag`, y ejecuta un Quality Gate con las reglas críticas del contrato:

- Gold no vacío.

- `id_cliente` no nulo y único.
- `churn_risk` dentro de Alto, Medio o Bajo.
- `consumo_promedio_gb` ≥ 0 .
- `pqr_abiertos` $\leq$ `total_pqr`.

Si alguna regla falla, el notebook genera un error antes de ejecutar `saveAsTable(GOLD)`. Por ello, no se publica una nueva versión y se conserva la última versión válida. Las condiciones como `ciudad` No informado, `estrato` imputado, `producto` sin capacidad identificable y registros enviados a cuarentena se manejan como reglas de monitoreo, no como bloqueos.

T4. Spark SQL vs. PySpark

Spark SQL y PySpark se ejecutan sobre el mismo motor distribuido de Spark; la diferencia principal está en la forma de expresar la lógica.

Criterio	Spark SQL	PySpark / DataFrame API
Mejor uso	Consultas analíticas, agregaciones y validaciones fáciles de leer	Ingesta, transformaciones reutilizables, lógica condicional y automatización
Legibilidad para negocio	Alta: es similar a SQL tradicional	Menor para usuarios no técnicos
Reutilización	Menor cuando se repiten reglas entre fuentes	Mayor mediante funciones, parámetros y estructuras reutilizables
Caso aplicado	P5 sobre Gold	Ingesta, Silver, cuarentena, trazabilidad y Quality Gate

En esta solución se usó PySpark para leer CSV, agregar metadatos, aplicar conversiones de tipo, deduplicar, validar integridad referencial, enviar registros de uso a cuarentena y construir Gold. Se usó Spark SQL en P5 porque es una consulta de consumo sobre Gold y permite expresar claramente el agrupamiento por segmento y ciudad.

La elección no es excluyente: PySpark se usa para procesamiento operacional y SQL para consumo analítico y consultas que deben ser fácilmente revisables.

T5. CI/CD e Infraestructura como Código

La estrategia propuesta es versionar código, configuración y documentación en Git, y promover el pipeline entre ambientes mediante Pull Request y validaciones previas al despliegue.

Rama de trabajo → Pull Request → revisión de código → pruebas de calidad e integración → despliegue en desarrollo → aprobación → despliegue en producción

Los notebooks, el data contract, la estrategia de producción y el diagrama deben permanecer versionados en el repositorio. El Job puede declararse con Databricks Asset Bundles para mantener tareas, dependencias, parámetros y schedules como código; así, un cambio de ruta o notebook no se realiza manualmente en cada ambiente.

Terraform complementa este enfoque cuando existan permisos corporativos, para declarar catálogos, esquemas, grants, identidades, external locations y políticas de compute.

Antes de desplegar se debe validar:

- Ejecución de controles de calidad e integración.
- Cumplimiento del Quality Gate de Gold.
- Actualización del contrato si cambian esquema, SLA o reglas de negocio.
- databricks bundle validate antes de desplegar el Job.

Actualmente el Job fue creado y validado manualmente de extremo a extremo. Para producción, se recomienda declarar su configuración en Asset Bundles y desplegarla mediante CI/CD.

T6. Validaciones antes de certificar Gold

Antes de publicar una nueva versión de cliente_360_churn_upsell, se ejecuta un Quality Gate.

Validación	Motivo	Acción si falla
Gold no vacío	Evita publicar un producto sin población de clientes activos	Bloquear publicación
id_cliente no nulo y único	Garantiza un registro por cliente activo	Bloquear publicación
churn_risk válido	Restringe los valores a Alto, Medio o Bajo	Bloquear publicación

consumo_promedio_gb >= 0	Evita exponer consumo inconsistente	Bloquear publicación
pqr_abiertos <= total_pqr	Garantiza consistencia entre indicadores PQR	Bloquear publicación

Si una regla crítica falla, el notebook termina con error antes de sobrescribir Gold y se conserva la última versión válida.

Como monitoreo se registran, sin bloquear por sí solos, producto sin capacidad identificable, ciudad No informado, estrato imputado y registros de uso en cuarentena.

T7. Autonomía gobernada

Autonomía gobernada significa que el dominio que conoce y produce los datos puede decidir cómo modelarlos y mantenerlos, pero debe cumplir reglas corporativas de seguridad, calidad y trazabilidad.

En términos de negocio: Postpago Residencial puede entregar rápidamente información para campañas de retención y upsell porque controla su producto Cliente 360. Sin embargo, no publica cualquier información: antes de habilitar el consumo por Mercadeo Digital, el pipeline valida calidad, protege datos sensibles y deja trazabilidad del origen y de cada ejecución.

El dominio define las reglas de churn_risk, upsell_flag y tratamientos de calidad. El gobierno corporativo se mantiene mediante:

- Unity Catalog para catálogo, permisos, linaje y auditoría.
- Data contract para responsables, esquema, SLA, calidad y acceso.
- Quality Gate que bloquea Gold si falla una regla crítica.
- Mínimo privilegio: Gold no incluye documento ni nombre completo y los consumidores usan una vista autorizada.

El resultado es un equilibrio entre agilidad del dominio y control corporativo sobre datos confiables y seguros.